

Segmentação da Coluna Vertebral Utilizando YOLOv8

Aluno: Rafael Barbosa Costa (MATRÍCULA:20219029996)
E-mail: rafaelcostabarbosa3@gmail.com; Período da Graduação: VII
Orientador: Antônio Oseas de Carvalho Filho

22 de julho de 2024

Resumo

Contexto: A coluna cervical, composta por sete vértebras e conectada à coluna torácica, é fundamental para a estabilidade do nosso corpo e proteção do sistema nervoso central. Profissionais de saúde enfrentam desafios significativos devido à complexidade e variedade de patologias que afetam essa área. Nesse contexto, a segmentação de imagens possibilita a identificação precisa de estruturas e anormalidades, desempenhando um papel essencial no diagnóstico preciso de condições como lesões traumáticas e doenças. Isso não apenas reduz o tempo de análise manual, mas também minimiza erros potenciais. Dessa forma, o YOLOv8 se destaca como uma ferramenta eficiente, precisa e rápida para essa segmentação, promovendo melhorias tangíveis nos cuidados de saúde e garantindo resultados mais confiáveis e objetivos.

Problema: A coluna cervical é uma estrutura anatomicamente complexa, e sintomas de diferentes condições podem se sobrepor ou serem confundidos. Além disso, algumas patologias da coluna cervical podem ser assintomáticas ou apresentar sintomas vagos, dificultando o diagnóstico precoce e o início do tratamento adequado. Essas dificuldades podem levar a atrasos no diagnóstico, sub ou superestimação de condições médicas e até mesmo a erros de tratamento.

Proposta: Este pré-projeto tem como objetivo principal investigar a aplicação do YOLOv8 na segmentação da coluna cervical em imagens médicas, buscando aprimorar a precisão e a eficiência do diagnóstico e tratamento de condições cervicais. Ao avançar na precisão da segmentação, espera-se proporcionar uma ferramenta robusta e confiável para profissionais de saúde, contribuindo assim para o progresso contínuo no campo do processamento de imagens médicas e promovendo melhores resultados clínicos e o bem-estar dos pacientes.

Palavras-chaves: Segmentação, YOLOv8, Coluna Cervical, Redes Neurais, Tomografia.

1 Introdução

A espinha dorsal, composta por 33 ossos, é uma das estruturas fundamentais do corpo humano. Além de proporcionar suporte e mobilidade, desempenha um papel crucial na proteção da medula espinhal, o elo vital entre o cérebro e as diversas partes do corpo, sendo essencial para o funcionamento do sistema nervoso. Os ossos da espinha dorsal são

agrupados em cinco regiões distintas: cervical, torácica, lombar, sacro e cóccix. Cada uma dessas regiões desempenha funções específicas na sustentação do corpo e na proteção dos nervos que percorrem a coluna vertebral.


A detecção de órgãos de risco na coluna muitas vezes requer uma avaliação cuidadosa por parte de um especialista, geralmente com base em imagens de tomografia computadorizada (TC). No entanto, essa análise pode ser demorada, o que não é ideal quando se trata de diagnósticos urgentes. Reduzir o tempo de espera para os pacientes é crucial para evitar complicações.

O campo da Patologia Digital utiliza técnicas de Processamento Digital de Imagens e Visão Computacional para realizar análises de tecidos biológicos(NIAZI; PARWANI; GURCAN, 2019). Nos últimos anos, houve uma tendência crescente no uso de métodos em Deep Learning, especialmente as redes neurais convolucionais (CNNs), para a análise de imagens histológicas(LITJENS et al., 2017), apesar de estas técnicas existirem há bastante tempo.

Aprendizado de máquina refere-se à capacidade dos algoritmos de melhorar automaticamente com a experiência(MITCHELL, 1997). Dentro desse campo, o Deep Learning é uma subárea que se beneficia do aumento da capacidade computacional dos últimos anos para realizar aprendizado mais complexo. Com isso, sugere-se a implementação de uma rede neural convolucional utilizando o modelo YOLOv8 para acelerar esse processo de detecção e diagnóstico(GLENN; AYUSH; JING, 2023). Duas vantagens distintas destacam-se nesse domínio: a escalabilidade, que permite lidar eficientemente com conjuntos de dados volumosos, superando as limitações das técnicas tradicionais de aprendizado de máquina e a transferência de conhecimento, que envolve a capacidade de utilizar informações aprendidas em um conjunto de dados para realizar tarefas em outro, mesmo que estes não guardem relação direta. Essa última característica é particularmente útil em situações em que os dados são escassos.

1.1 Objetivos Gerais e Específicos

O objetivo deste trabalho é explorar e otimizar o uso da arquitetura YOLOv8 para segmentação eficiente da coluna cervical em imagens médicas, com o intuito de desenvolver uma ferramenta precisa e ágil para delimitar a região da medula espinhal. Este estudo visa facilitar o acompanhamento dos efeitos do tratamento de lesões na medula espinhal, através de uma segmentação precisa e em tempo real, proporcionando uma compreensão detalhada dos efeitos clínicos e possibilitando intervenções clínicas mais ágeis e eficazes. Os objetivos específicos são:

1. Adquirir um conjunto de dados de imagens médicas da região cervical.
2. Treinar e validar o modelo visando alcançar uma sensibilidade elevada.
3. Realizar inferências com tempo de resposta reduzido. 
4. Garantir a acessibilidade dos resultados e do software necessário para reprodução.

2 Justificativa

A segmentação eficiente da coluna cervical desempenha um papel fundamental no acompanhamento e tratamento de pacientes com lesões na medula espinhal. A utilização da



arquitetura YOLOv8 para esse fim apresenta-se como uma abordagem promissora devido à sua capacidade de segmentação rápida e precisa em imagens médicas. A arquitetura YOLOv8, conhecida por sua alta eficiência e precisão em tarefas de detecção e segmentação em tempo real, pode proporcionar avanços significativos na análise de imagens médicas, especialmente na detecção de estruturas anatômicas complexas como a coluna cervical.

No entanto, apesar do potencial dessa técnica, ainda há uma lacuna na literatura em relação à aplicação específica de YOLOv8 na segmentação da coluna cervical para fins relacionados a lesões na medula espinhal. A maioria dos estudos existentes concentra-se em outras partes do corpo ou em diferentes abordagens de segmentação, deixando uma necessidade crítica de pesquisa direcionada a esta aplicação específica. A precisão na segmentação da coluna cervical é crucial, pois permite a identificação precisa de áreas lesionadas, facilitando o planejamento de intervenções cirúrgicas e terapêuticas.



Portanto, este estudo se justifica pela necessidade de preencher essa lacuna, fornecendo uma solução inovadora e eficaz para a delimitação da medula espinhal em pacientes com lesões. A implementação bem-sucedida desse método pode facilitar o monitoramento contínuo dos efeitos do tratamento, permitindo intervenções mais assertivas e melhorando significativamente os resultados clínicos e a qualidade de vida dos pacientes. Além disso, ao integrar técnicas avançadas de inteligência artificial e aprendizado profundo, como o YOLOv8, com dados de alta qualidade provenientes de tomografias, este estudo pode estabelecer novos padrões para a segmentação de imagens médicas.

3 Referencial Teórico

Esta seção fornecerá uma base conceitual fundamental para a compreensão deste pré-projeto. Abordaremos os conceitos de aprendizado de máquina, aprendizado profundo e redes de detecção de objetos.

3.1 Segmentação na Coluna Vertebral

Uma imagem é a manifestação visual de um objeto ou cena, composta por uma vasta coleção de pixels que oferecem uma riqueza de detalhes. No âmbito do processamento digital de imagens, a segmentação desempenha um papel crucial e desafiador. Envolve a extração, análise e compreensão de dados relevantes de uma única imagem ou de uma sequência delas, através da divisão da imagem em segmentos distintos e não sobrepostos que contêm informações valiosas.

Ao dividir imagens grandes em múltiplos segmentos menores, com base em propriedades como intensidade de cor ou valores de pixels, podemos obter uma análise mais eficiente e precisa. Processar uma imagem inteira de uma só vez pode ser ineficiente, pois demanda muito tempo computacional. Portanto, as técnicas de segmentação de imagens são mais adequadas para reduzir o tempo de processamento, permitindo uma abordagem mais focada e eficiente na extração de informações úteis(MAHESWARI; KORAH, 2016).

Uma das etapas mais desafiadoras nesse processo é a escolha do método de segmentação. Essa fase determina o sucesso ou fracasso da análise da imagem, especialmente quando a visualização de órgãos é crucial(BANKMAN, 2008). Atualmente, as modalidades de imagens médicas produzem alta resolução e um grande volume de imagens, inviáveis para análise manual. Isso impulsiona o desenvolvimento de soluções mais eficazes e robustas, adequadas aos desafios dos métodos de análise de imagens médicas.

A segmentação pode aprimorar a precisão ao eliminar a subjetividade do clínico. Além disso, economiza tempo e esforço ao eliminar processos exaustivos nos quais os resultados são raramente repetíveis(HARRIS et al., 1999).

O processo automatizado de segmentação da coluna vertebral, usado para criar modelos 3D anatomicamente precisos, enfrenta diversos desafios. Alguns desses desafios estão relacionados à complexidade anatômica da coluna vertebral, que inclui 33 vértebras, 23 discos intervertebrais, a medula espinhal, nervos conectados, entre outros elementos. Além disso, há o desafio do ruído presente nas imagens (todos os dados de imagens de TC contêm algum nível de ruído), a baixa intensidade em regiões de ossos esponjosos e tecidos mais moles, e o efeito de volume parcial.

3.2 Aprendizado de máquina

A aprendizagem de máquina é um vasto domínio que abrange diversas áreas, como tecnologia da informação, estatística, probabilidade, inteligência artificial, psicologia e neurobiologia, entre outras disciplinas. Com a aprendizagem automática, problemas podem ser abordados pela construção de modelos que representam de forma eficaz conjuntos de dados específicos. Essa disciplina evoluiu significativamente, passando desde o ensino de computadores para imitar o funcionamento do cérebro humano até transformar o campo da estatística em uma disciplina abrangente, gerando teorias estatísticas computacionais sobre processos de aprendizagem.

A essência do aprendizado de máquina reside na elaboração de algoritmos que capacitem os computadores a aprenderem. Esse processo envolve a identificação de regularidades estatísticas ou outros padrões nos dados. Os algoritmos de aprendizado de máquina(TAIWAR; KUMAR, 2013), são concebidos para espelhar a abordagem humana ao aprendizado de uma tarefa específica. Além disso, esses algoritmos também podem refletir uma compreensão da complexidade relativa do aprendizado em diversos ambientes.

Atualmente, com o avanço das tecnologias de computação no campo do Big Data, o aprendizado de máquina não se assemelha ao que era no passado. Vimos um grande desenvolvimento(CARUANA; NICULESCU-MIZIL, 2006), atualização e refinamento de muitos algoritmos de aprendizado de máquina. O progresso recente nesse campo tem se concentrado na capacidade de automatizar a aplicação de uma ampla gama de cálculos matemáticos complexos em conjuntos de dados extensos, resultando em análises consideravelmente mais rápidas.

A programação adaptativa desfruta de grande popularidade, especialmente no campo do aprendizado de máquina. Nessa área, as aplicações podem reconhecer padrões, aprender com experiências passadas, extrair novas informações dos dados e aprimorar a precisão e eficiência de seus processamentos e resultados. Além disso, as técnicas de aprendizado de máquina(AYODELE, 2010) são aplicadas para lidar com dados multidimensionais em uma variedade de contextos.

3.3 Aprendizado Profundo



Deep Learning é uma disciplina dentro do campo do aprendizado de máquina que utiliza algoritmos para processar dados e emula o processo de pensamento humano para desenvolver previsões. Essa abordagem utiliza métodos de aprendizado de máquina centrados na representação de dados. O Deep Learning emprega camadas de algoritmos para

processar informações, compreender a linguagem humana e identificar objetos visualmente. É uma ramificação do aprendizado de máquina artificial, inspirada em redes neurais.

Segundo(LECUN; BENGIO; HINTON, 2015), o Deep Learning está se destacando ao oferecer soluções para problemas desafiadores enfrentados há muitos anos no campo da Inteligência Artificial. Ele também obteve sucesso significativo em diversas áreas da ciência, especialmente no processamento de imagens e sons, incluindo reconhecimento facial, de fala e visão computacional, entre outros. Em 2015, uma publicação destacou sua superioridade sobre outras técnicas de aprendizado de máquina em aspectos gerais da inteligência artificial. Simplificadamente, pode ser descrito como um conjunto de métodos de aprendizagem que modelam dados por meio de uma arquitetura complexa, inspirada na estrutura e função do cérebro, onde as redes neurais de várias camadas são combinadas para formar uma rede neural profunda.

O aprendizado profundo tem encontrado aplicação em diversas áreas, especialmente em Visão Computacional, como Processamento de Imagens e Computação Gráfica. Técnicas como Redes Neurais Convolucionais (CNNs), Redes de Crenças Profundas (Deep Belief Networks), Máquinas Restritas de Boltzmann (Restricted Boltzmann Machines) e Autoencoders têm se destacado como fundamentais para os métodos de vanguarda em várias aplicações(DONG; WANG; ABBAS, 2021).

3.4 YOLO

Visando à aplicação prática da segmentação da coluna cervical para classificar imagens por tipo, é essencial ter um bom desempenho do detector de objetos, com resultados precisos nas métricas. Com esse objetivo, optamos pela rede YOLO, que ao longo de suas versões, tem passado por desenvolvimentos, cada um trazendo melhorias e refinamentos.

O YOLOv8(JOCHER; CHAURASIA; QIU, 2023) é o mais recente modelo YOLO desenvolvido pela Ultralytics, a mesma empresa que criou o YOLOv5. Lançado em 10 de janeiro de 2023, o YOLOv8 já teve cinco versões: YOLOv8n (nano), YOLOv8s (small), YOLOv8m (medium), YOLOv8l (large) e YOLOv8x (extra large). Sendo um modelo de última geração, ainda não foi publicado um artigo revisado por pares, mas o YOLOv8 está disponível no repositório da Ultralytics.

O YOLOv8 é um modelo avançado para detecção de objetos e segmentação de imagens. Além disso, oferece suporte integrado para tarefas de classificação de imagens, apresentando várias mudanças e melhorias em comparação com o YOLOv5, tanto em termos de arquitetura quanto de experiência do desenvolvedor. O modelo é desenvolvido em PyTorch e é compatível tanto com CPU quanto com GPU.

4 Trabalhos Relacionados

Nesta seção, serão abordados os trabalhos relacionados que possuem relevância para esta pesquisa. A Tabela 1 apresenta uma comparação desses trabalhos, avaliando-os com base nos seguintes critérios: foco principal da solução, a utilização da YOLOv8 e a segmentação na coluna vertebral. Esses critérios são fundamentais para entender como outras soluções têm sido desenvolvidas e quais lacunas ainda existem. Aqui está uma visão mais aprofundada dos critérios e das comparações feitas na tabela:

Foco Principal da Solução: Este critério avalia o objetivo central de cada estudo. Os trabalhos variam amplamente, desde a segmentação de imagens da coluna vertebral

para diagnósticos médicos até a detecção de danos em aerogeradores e a aplicação de visão computacional na gestão de TI.

Utilização da YOLOv8: A YOLOv8 é um modelo avançado de detecção de objetos que se destaca pela sua precisão e eficiência. A tabela avalia se os trabalhos utilizam ou não a YOLOv8 em suas abordagens. Alguns trabalhos adotam a YOLOv8 para diferentes propósitos, enquanto outros utilizam diferentes métodos ou não utilizam a YOLOv8.

Segmentação da Coluna Vertebral: Este critério examina se o estudo aborda a segmentação da coluna vertebral, um processo crítico para diagnósticos médicos precisos e intervenções cirúrgicas.

O artigo (PAULO, 2018) propõe um método para segmentação da coluna vertebral humana utilizando imagens externas da região dorsal. O estudo foi realizado com 70 voluntários e utilizou um algoritmo chamado DISLo (Dorsal Image Spine Locator), que processa as imagens baseando-se na informação visível e produz uma imagem binária representando a coluna vertebral identificada. O método foi avaliado pela precisão da segmentação comparada a uma realizada manualmente, e os resultados mostraram que é uma abordagem viável e confiável para a avaliação da coluna vertebral, com potencial para reduzir custos e tempo em diagnósticos médicos.

O artigo (VIANA, 2022) apresenta o desenvolvimento de um simulador para treinamento cirúrgico. Esse simulador utiliza técnicas de segmentação 3D de imagens médicas para criar modelos anatômicos específicos do paciente. O objetivo é melhorar as habilidades técnicas dos cirurgiões e contribuir para a segurança e eficiência dos procedimentos cirúrgicos de correção da escoliose. Além disso, o trabalho discute a aplicação de exames de tomografia computadorizada (TC) na segmentação da anatomia da coluna vertebral.

O trabalho (MARQUES, 2023) propõe uma metodologia baseada em Inteligência Artificial (IA) e Visão Computacional para a detecção e análise de danos em aerogeradores. O objetivo é desenvolver um sistema que possa identificar e segmentar danos e acúmulos de sujeira nas superfícies externas dos aerogeradores em tempo real, utilizando imagens de alta resolução capturadas por Veículos Aéreos Não Tripulados (VANTs). A metodologia utiliza quatro arquiteturas do modelo YOLOv8 para detecção e o modelo Segment Anything Model (SAM) para segmentação das imagens. O modelo YOLOv8-Small se destacou nos testes, mostrando-se eficiente na detecção de sujeiras e danos com alta precisão e velocidade. O SAM teve um bom desempenho na segmentação de danos, mas não foi tão eficaz na segmentação de sujeiras. Portanto, a metodologia é recomendada principalmente para a detecção e segmentação de danos.

Este trabalho (PIRES, 2023) discute a aplicação da Visão Computacional na Gestão da Tecnologia da Informação. Ele aborda como essa tecnologia, que integra Inteligência Artificial, Aprendizado de Máquina e Aprendizado Profundo, pode otimizar processos e melhorar a segurança no ambiente de trabalho, especialmente através da detecção automática do uso de Equipamentos de Proteção Individual (EPIs). O artigo também detalha o uso de Redes Neurais Convolucionais (CNN) para aprimorar a eficiência e a tomada de decisões em TI. Além disso, sugere futuras melhorias e aplicações, como o treinamento prolongado de modelos e a implementação de sistemas de rastreamento e alerta para a segurança no trabalho.

Este documento (JUNIOR et al.,) tem como objetivo desenvolver datasets odontológicos e validar seu uso através de técnicas de inteligência artificial, especialmente com

redes neurais artificiais. O dataset utilizado contém 271 imagens de raio-X interproximal anotadas em 5 classes: dente, restauração, tratamento de canal, implante dentário e coroa dentária. A pesquisa envolveu a implementação de infraestrutura na AWS, treinamento de modelos como U-Net, Mask R-CNN e YOLOv8, e análise dos resultados obtidos. Embora os modelos tenham tido sucesso na previsão das classes mais representativas, houve dificuldades com classes menos frequentes, como implante e coroa.

Por fim, este pré-projeto é o único que integra todas as funcionalidades necessárias para uma solução completa na segmentação da coluna vertebral, incluindo o uso de tecnologia de processamento de imagem com o modelo YOLOv8. Dentre todos os artigos apresentados, nenhum deles faz uso de YOLOv8 para essa finalidade específica, o que destaca a inovação e a singularidade da abordagem proposta. Este pré-projeto visa aprimorar significativamente o diagnóstico e a avaliação das condições da coluna vertebral, permitindo uma detecção mais precisa e rápida de anomalias. A aplicação do modelo YOLOv8 possibilita a segmentação detalhada e eficiente das imagens da coluna vertebral, melhorando a acurácia dos diagnósticos médicos.

Tabela 1 – Trabalhos relacionados

Trabalho	Foco	Utilização da YOLOv8	Segmentação da Coluna Vertebral
(PAULO, 2018)	Segmentação da Coluna Vertebral Utilizando Imagens da Região Dorsal	Não	Sim
(VIANA, 2022)	Simulador para Treinamento Cirúrgico na Correção da Escoliose	Não	Sim
(MARQUES, 2023)	Detecção e Segmentação Automática de Danos e Sujeiras em Aerogeradores.	Sim	Não
(PIRES, 2023)	Aplicação da Visão Computacional na Gestão da Tecnologia da Informação (TI)	Sim	Não
(JUNIOR et al.,)	Auxiliar no Diagnóstico Odontológico Através do Uso de Aprendizado de Máquina.	Sim	Não
Este pré-projeto	Aplicação do Modelo YOLOv8 para a Segmentação da Coluna Vertebral em Imagens Médicas	Sim	Sim

No estudo de (PAULO, 2018), o método DISLo utiliza imagens externas da região dorsal para segmentar a coluna vertebral. A limitação principal aqui é que esse método pode não capturar detalhes internos da coluna, essenciais para um diagnóstico preciso. No trabalho de (VIANA, 2022), a criação de um simulador para treinamento cirúrgico

baseado em segmentação 3D de imagens médicas é altamente benéfica, mas enfrenta desafios significativos relacionados ao custo e acessibilidade dos exames de tomografia computadorizada (TC). Esses exames são caros e nem sempre estão disponíveis em todas as instituições médicas. O estudo de (MARQUES, 2023) utiliza o modelo YOLOv8 e o Segment Anything Model (SAM) para a detecção e segmentação de danos em aerogeradores. A segmentação de diferentes tipos de defeitos apresenta desafios específicos, e nem todos os modelos conseguem lidar com essas variabilidades com a mesma eficácia. O artigo de (PIRES, 2023) discute a aplicação de Visão Computacional na gestão da Tecnologia da Informação, focando na detecção automática do uso de Equipamentos de Proteção Individual (EPIs). Embora o uso de Redes Neurais Convolucionais (CNN) tenha mostrado bons resultados, a especificidade dos dados e contextos utilizados pode limitar a generalização para outras aplicações. O trabalho de (JUNIOR et al.,) foca na criação de datasets odontológicos e validação através de técnicas de inteligência artificial. A principal dificuldade enfrentada foi a previsão de classes menos frequentes, como implantes e coroas, devido ao desequilíbrio no dataset.

Para que este pré-projeto se destaque em relação aos outros mencionados, é essencial implementar diversas melhorias e abordagens inovadoras. A combinação de imagens externas de alta resolução com exames internos, como tomografias, é fundamental para superar as limitações associadas a cada tipo de imagem. Essa combinação permitirá uma visão mais completa e precisa da coluna vertebral, melhorando significativamente a precisão da segmentação.

5 Esboço da Proposta

Este pré-projeto integra as funcionalidades necessárias para uma solução completa na segmentação da coluna vertebral, incluindo o uso de tecnologia de processamento de imagem com o modelo YOLOv8. Dentre todos os artigos apresentados, nenhum deles faz uso de YOLOv8 para essa finalidade específica, o que destaca a inovação e a singularidade da abordagem proposta. Este pré-projeto visa aprimorar significativamente o diagnóstico e a avaliação das condições da coluna vertebral, permitindo uma detecção mais precisa e rápida de anomalias.



A aplicação do modelo YOLOv8 possibilita a segmentação detalhada e eficiente das imagens da coluna vertebral, melhorando a acurácia dos diagnósticos médicos. A integração dessa tecnologia pode reduzir o tempo necessário para a análise das imagens e diminuir a margem de erro associada ao diagnóstico humano. Com isso, a utilização do YOLOv8 no contexto proposto representa um avanço significativo em relação aos métodos tradicionais, contribuindo para a evolução das práticas médicas e trazendo benefícios concretos tanto para os profissionais de saúde quanto para os pacientes..

Uma das etapas mais inovadoras e desafiadoras deste trabalho será a segmentação das regiões de interesse nas imagens. Essa técnica permitirá localizar precisamente as áreas relevantes da coluna vertebral e eliminar possíveis ruídos que possam interferir nos resultados. Posteriormente, serão extraídas características morfológicas relevantes das imagens, que servirão de base para os algoritmos de segmentação.

Para solucionar o problema da segmentação da coluna vertebral, será necessário realizar uma busca de imagens em bases públicas contendo imagens de coluna vertebral. Com as imagens coletadas, será possível montar uma base privada que servirá de entrada para os modelos de detecção de objetos. Dessa forma, eles poderão identificar, ao final,

a região da coluna vertebral. Os modelos escolhidos farão a segmentação da região da coluna vertebral com base nas áreas detectadas. Como já mostrado anteriormente, a rede de detecção de objetos a ser utilizada será o YOLOv8.



Com o modelo devidamente treinado, o próximo passo é realizar a segmentação da coluna vertebral. Esta etapa é crucial para o resultado final, pois as regiões detectadas podem conter anomalias. Por fim, o modelo de aprendizado de máquina será desenvolvido para segmentar com precisão as imagens da coluna vertebral com base nas características extraídas.



- Verdadeiro Positivo (VP): Indica uma classificação correta na classe Positiva.
- Falso Positivo (FP): Indica uma classificação incorreta na classe Positiva; o resultado real deveria ser da classe Negativa.
- Verdadeiro Negativo (VN): Indica uma classificação correta na classe Negativa.
- Falso Negativo (FN): Indica uma classificação incorreta na classe Negativa; o resultado real deveria ser da classe Positiva.

A acurácia oferece uma visão geral do desempenho do modelo, indicando a precisão das suas classificações. Ela é expressa pela seguinte fórmula:

$$Acurácia = \frac{VP + VN}{VP + VN + FP + FN}$$

A precisão avalia as classificações da classe positiva, indicando quantas delas estão corretas de maneira geral. A fórmula para calcular a precisão é a seguinte:

$$Precisão = \frac{VP}{VP + FP}$$

O recall avalia todas as instâncias que realmente pertencem à classe positiva e qualifica quantas delas foram corretamente identificadas. A fórmula para calcular o recall é a seguinte:

$$Recall = \frac{VP}{VP + FN}$$

E por fim, o F1-score combina a precisão e o recall de forma harmoniosa, sendo expresso pela seguinte fórmula:

$$F1 - score = \frac{2 \times Precisão \times Recall}{Precisão + Recall}$$

6 Metodologia e Cronograma

Nesta seção será abordada a metodologia para o processo de segmentação da coluna vertebral, utilizando o modelo YOLOv8. A metodologia adotada consiste nas seguintes etapas: revisão bibliográfica, definição das métricas de avaliação, coleta de imagens, treinamento e avaliação do modelo de segmentação, análise dos resultados obtidos.




Figura 1 – Fluxograma da metodologia adotada para segmentação da coluna vertebral.

A Figura 1 apresenta um modelo baseado em UML (Unified Modeling Language) que ilustra a metodologia descrita.

Fase 1 - Levantamento bibliográfico: O primeiro passo será o levantamento bibliográfico, pois ali serão encontrados trabalhos relevantes caso já tenham sido utilizadas técnicas de detecção de objetos e, por fim, obter conhecimento técnico e uma compreensão mais aprofundada do problema resolvido.

Fase 2 - Definição das métricas utilizadas na avaliação: As seguintes métricas serão utilizadas para avaliar a qualidade das detecções: pontuação F1, exatidão, precisão e recall.

Fase 3 - Aquisição de imagens: É necessária uma base de dados de imagens para o treinamento e avaliação dos métodos sugeridos, portanto será realizada uma busca em bases de dados abertas que já foram utilizadas para outros projetos. **E desenvolver sua própria base em colaboração com outros laboratórios.**



Fase 4 - Treinamento e a avaliação do modelo de detecção **Utilizaremos uma base de imagens específica desenvolvida para este propósito, e aplicaremos as métricas mencionadas previamente para avaliação de desempenho.**



Fase 5 - Análise dos resultados: A precisão das detecções será analisada utilizando as métricas previamente definidas. Os resultados obtidos pelo modelo serão comparados com trabalhos anteriores que também utilizaram detecção de objetos.

E Por último, o cronograma estabelecido para o desenvolvimento deste projeto é apresentado na Tabela 2:

Tabela 2 – Cronograma

Atividade	Mês	Mês	Mês	Mês	Mês
	1-2	3-6	7-8	9-10	11-12
Levantamento Bibliográfico	X				
Definição de métricas de avaliação	X				
Aquisição de imagens	X	X			
Treinamento e avaliação do modelo de detecção		X	X		
Análise dos resultados			X		
Redação da monografia			X	X	
Apresentação da monografia					X

Referências

- AYODELE, T. O. *Types of machine learning algorithms in new advances in machine learning. croatia, rijeka*. [S.l.]: InTech, 2010. Citado na página 4.
- BANKMAN, I. *Handbook of medical image processing and analysis*. [S.l.]: Elsevier, 2008. Citado na página 3.
- CARUANA, R.; NICULESCU-MIZIL, A. An empirical comparison of supervised learning algorithms. In: *Proceedings of the 23rd international conference on Machine learning*. [S.l.: s.n.], 2006. p. 161–168. Citado na página 4.
- DONG, S.; WANG, P.; ABBAS, K. A survey on deep learning and its applications. *Computer Science Review*, Elsevier, v. 40, p. 100379, 2021. Citado na página 5.
- GLENN, J.; AYUSH, C.; JING, Q. Yolo by ultralytics. *Ultralytics*, 2023. Citado na página 2.
- HARRIS, G. et al. Improving tissue classification in mri: a three-dimensional multispectral discriminant analysis method with automated training class selection. *Journal of computer assisted tomography*, LWW, v. 23, n. 1, p. 144–154, 1999. Citado na página 4.
- JOCHER, G.; CHAURASIA, A.; QIU, J. Yolo by ultralytics. Jan, 2023. Citado na página 5.
- JUNIOR, W. D. D. S. et al. Deeprad: Auxílio em diagnóstico odontológico por aprendizado de máquina. Citado 3 vezes nas páginas 6, 7 e 8.
- LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. *nature*, Nature Publishing Group UK London, v. 521, n. 7553, p. 436–444, 2015. Citado na página 5.
- LITJENS, G. et al. A survey on deep learning in medical image analysis. *Medical image analysis*, Elsevier, v. 42, p. 60–88, 2017. Citado na página 2.
- MAHESWARI, S.; KORAH, R. Review on image segmentation based on color space and its hybrid. In: IEEE. *2016 International Conference on Control, Instrumentation, Communication and Computational Technologies (ICCICCT)*. [S.l.], 2016. p. 639–641. Citado na página 3.
- MARQUES, L. T. *Metodologia Baseada em IA e Visão Computacional para Detecção e Análise de Danos em Aerogeradores*. Dissertação (B.S. thesis) — Universidade Federal do Rio Grande do Norte, 2023. Citado 3 vezes nas páginas 6, 7 e 8.
- MITCHELL, T. *Machine Learning*. McGraw-Hill, 1997. (McGraw-Hill International Editions). ISBN 9780071154673. Disponível em: <<https://books.google.com.br/books?id=EoYBngEACAAJ>>. Citado na página 2.
- NIAZI, M. K. K.; PARWANI, A. V.; GURCAN, M. N. Digital pathology and artificial intelligence. *The lancet oncology*, Elsevier, v. 20, n. 5, p. e253–e261, 2019. Citado na página 2.

PAULO, J. V. d. Segmentação da coluna vertebral humana por meio do processamento de imagens externas da região dorsal. 2018. Citado 2 vezes nas páginas 6 e 7.

PIRES, R. L. Visão computacional aplicada na gestão da tecnologia da informação. 275, 2023. Citado 3 vezes nas páginas 6, 7 e 8.

TALWAR, A.; KUMAR, Y. Machine learning: An artificial intelligence methodology. *International Journal of Engineering and Computer Science*, v. 2, n. 12, p. 3400–3404, 2013. Citado na página 4.

VIANA, B. *Segmentação 3D e análise de imagens da coluna vertebral para treinamento cirúrgico na correção da escoliose*. Dissertação (B.S. thesis) — Universidade Federal do Rio Grande do Norte, 2022. Citado 2 vezes nas páginas 6 e 7.